小 型 微 型 计 算 机 系 统
Journal of Chinese Computer Systems
DOI:10.20009/j.cnki.21-1106/TP.2023-0589
2025 年 4 月 第 4 期
Vol.46 No.4 2025

多特征提取和网络嵌入的蛋白质交互网络比对

何浩发[1],马汇东[1],钟 诚[1,2]

[1](广西大学 计算机与电子信息学院,南宁 530004)
[2](广西高校并行分布与智能计算重点实验室,南宁 530004)
E-mail:2013391018@st.gxu.edu.cn

摘 要: 为快速获得高得分的拓扑和生物属性比对结果,提出一种利用生成式对抗网络的蛋白质交互网络全局比对高效方法.通过提取蛋白质网络中节点的序列比对得分、边的度、聚类系数和节点的 Page Rank 值,以组成节点的特征向量嵌入;将源网络的嵌入通过生成式对抗网络映射到目标网络的嵌入空间来得到初步比对结果;通过计算映射后嵌入向量之间的欧氏距离来获得最终比对结果.在真实的蛋白质交互网络数据集测试的结果表明,与已有的同类算法相比,在拓扑指标边正确性、诱导保守结构以及对称子图得分和基因同源一致性上,本文方法整体上具有优势.

关 键 词: 蛋白质交互网络;网络比对;生成式对抗网络;网络嵌入
中图分类号: TP301 **文献标识码:** A **文 章 编 号:** 1000-1220(2025)04-0847-09

Aligning Protein-protein Interaction Networks Using Multi-feature Extraction and Network Embedding

HE Haofa[1], MA Huidong[1], ZHONG Cheng[1,2]

[1](School of Computer, Electronics and Information, Guangxi University, Nanning 530004, China)
[2](Key Laboratory of Parallel, Distributed and Intelligent Computing in Guangxi Universities and Colleges, Nanning 530004, China)

Abstract: In order to quickly obtain alignment results with high-score topological and biological attribute, an efficient method for aligning global protein-protein interaction networks using generative adversarial networks is proposed. By extracting the sequence alignment score, edge degree, clustering coefficient, and Page Rank value of nodes in the network, the feature vector of the nodes is embedded. The embedding of the source network is mapped to the embedding space of the target network by generative adversarial network to obtain preliminary alignment results. The final alignment result is obtained by embedding the Euclidean distance between vectors after statistical mapping. The experimental results on the real protein-protein interaction network dataset show that compared with the existing methods, our proposed method overall has advantages for topological index edge correctness, induced conservative structure, symmetric subgraph score, and gene homology consistency.

Keywords: protein-protein interaction network; network alignment; generative adversarial networks; network embedding

0 引 言

随着高通量筛选技术的发展以及计算技术在生物领域的应用,大量的蛋白质交互(protein-protein interaction,PPI)数据被发现[1].这些蛋白质相互作用数据被抽象成一个以蛋白质作为节点、以蛋白质之间的相互作用作为边的图(网络).蛋白质交互网络比对(Protein-Protein Interaction Network Alignments,PPINA)问题是指通过计算比较的方法分析来自不同物种的 PPI 网络,以便发现共同的蛋白质组.这些共同的蛋白质组被称为保守复合物(conserved complexes),它们很可能是相关的,且在一个细胞中共享相似的功能.通过比对不同种或者同种生物中不同部分的蛋白质交互网络,可用于预测蛋白质或蛋白质复合物的功能和功能注释(Functional Annotation)、预测和验证蛋白质相互作用、检测同源性和重建系统发育树等[2-6].

多年来,学者们提出了多种成对蛋白质交互网络的全局比对算法,这些算法从设计方法上分成两大类:二步算法和基于目标函数的搜索算法.二步算法首先计算得到网络节点的相似度矩阵,将网络比对问题转化为最大权重的二部图匹配问题,然后使用经典算法或者贪婪算法策略来求解最大权重的二部图匹配问题.算法 IsoRank[7]、MI-GRAAL[8]、NetAl[9]、Mat3[10]和 HubAlign[11]都属于二步算法.采用基于目标函数的搜索算法进行网络比对是最近几年提出来的.这类比对算法首先提出一个目标函数,然后利用不同的启发式搜索策略去优化目标函数.属于这类的生物网络比对算法有 PISwap[12]、MAGNA[13]、MAGNA + +[14]和 Optnetalign[15]等.文献[16]通过对生物网络进行模块划分,计算模块相似性,然后通过模块直接比对选取候选集,最后通过超图比对匹配从而完成成对网络的比对.文献[17]融合生物网络中的多种拓扑信息,通过相关值计算特征向量中心性和得分,设计实

收稿日期:2023-12-07 收修改稿日期:2024-04-01 基金项目:国家自然科学基金项目(62362004,61962004)资助. 作者简介:**何浩发**,男,1996 年生,硕士研究生,研究方向为并行计算、生物信息计算;**马汇东**,男,1999 年生,硕士研究生,研究方向为并行计算、生物信息计算;**钟 诚**(通信作者),男,1964 年生,博士,教授,博士生导师,CCF 杰出会员,研究方向为并行计算、生物信息计算.

现了一种双网络比对算法 ECAlign. 文献[18]从输入网络中提取拓扑相似性信息,运用蚁群优化方法求解生物网络比对问题. 文献[19]对现有生物网络比对方法进行评估,然后采用包括投票技术之类的增强的集成方法选择当前最好的比对方法完成 PPI 网络的比对工作.

已有的成对蛋白质交互网络的全局比对算法比对结果的拓扑质量和生物质量之间不能同时取得较好的性能,且网络比对和子图同构问题一样都是 NP-hard 问题,只能使用启发式方法来获得结果,算法运行时间较长.

本文提出一种基于网络嵌入和多特征提取的蛋白质交互网络全局比对方法,以能够在较短的时间内获得较高的拓扑与生物比对得分的比对结果.

本文主要贡献如下:

1)通过捕获蛋白质交互数据中源网络和目标网络的多种拓扑属性获得源网络和目标网络的嵌入,充分挖掘网络中节点的相似性特征,以提升比对质量.

2)通过生成式对抗网络 GAN[20]将源网络的节点嵌入映射到目标网络所形成的空间中,以完成网络映射比对,比对的网络映射储存在 GAN 网络的生成器中.

3)运用 KD-tree[21]算法来快速处理源网络和目标网络之间的 GAN 网络映射,以减少算法整体的运行时间,并得到最终的比对结果.

1 方 法

本文提出的蛋白质交互网络全局比对方法的思想:第 1 步,通过将要比对的源网络 $G_s=(V_s,E_s)$ 和目标网络 $G_t=(V_t,E_t)$ 进行噪声处理,以将节点之间不可靠的边过滤掉得到增强的网络 G_s' 和 G_t'. 第 2 步,提取增强后网络 G_s' 和 G_t' 节点的特征向量集 $eig_s(v_s)$ 和 $eig_t(v_t)$. 第 3 步,将提取的特征向量集输入 GAN 网络的生成器和鉴别器中进行训练对准. 第四步,将源网络的特征向量集重新输入生成器中进行比对,通过运用 KD-tree 算法得到最终的映射节点对(最终的比对结果).

为方便理解,图 1 给出了本文提出的通过网络嵌入和多特征提取进行蛋白质交互网络全局比对的过程.

下面详细阐述本文比对方法的每个步骤.

1.1 剔除蛋白质网络中不可靠的边

由于生物数据获取方式的不同以及实验误差等,导致已有的生物网络数据是不完整的,且含有大量噪声和缺失的边,因此为了确保实验数据的完整性和结果的鲁棒性,需要进行噪声处理.

设源网络 $G_s=(V_s,E_s)$ 和目标网络 $G_t=(V_t,E_t)$,节点数 $|V_s|=n_s$,$|V_t|=n_t$,节点 $v_s\in V_s$ 和 $v_t\in V_t$. 不失一般性,本文假定 $n_s<n_t$.

在生物数据集中,蛋白质网络节点间的序列相似性 Blast 比对[22]得分的衡量包含了 s-值和 e-值,s 值来衡量生物数据的同源性(s 值越大表示同源性越高),而 e 值是 s 值的可靠性评价指标(e 值越小,s 值的可靠性越高). 本文采用文献[23]中给出的 e 值,即 $e<10^{-5}$. 在参与比对的源网络和目标网络中剔除 $e\geqslant 10^{-5}$ 的序列比对相似性得分,即剔除该得分对应的蛋白质交互网络中的边.

1.2 网络节点的特征提取

本文获取源和目标蛋白质交互网络中节点的拓扑特征——节点度、page rank 值和聚类系数[24]. 设 v 表示节点集合 v_s 或 v_t 中的任一节点,使用 $deg(v)$ 表示节点 v 的度,即与节点 v 直接相连的其他节点的个数. 在 PPI 网络中,$deg(v)$ 越大表示节点 v 重要性越高.

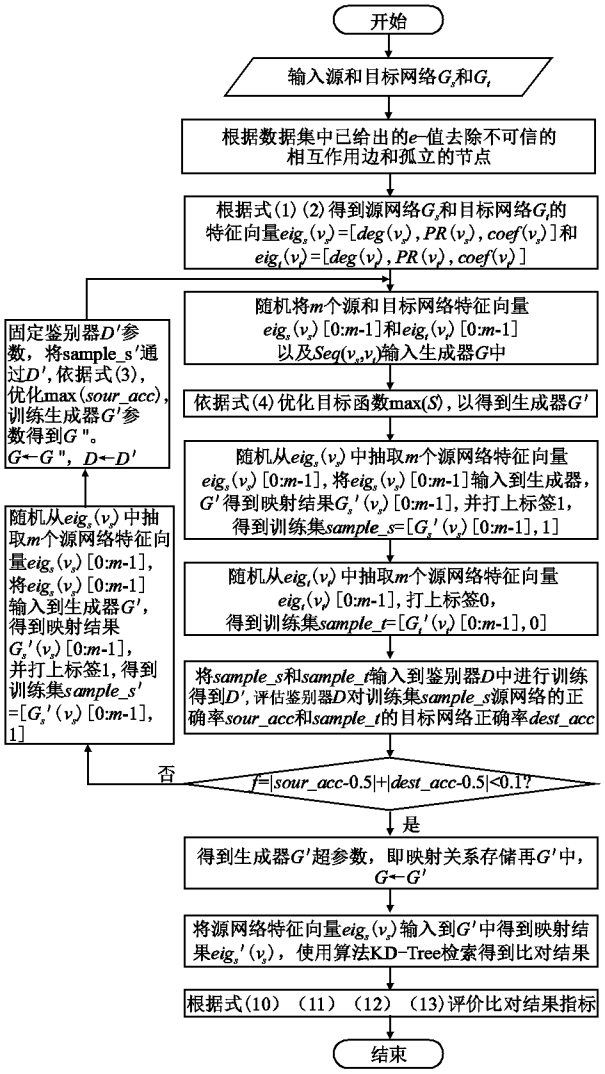


图 1 网络嵌入和多特征提取的 PPI 网络全局比对过程

Fig. 1 Process of aligning PPI networks using network embedding and multi-feature extraction

本文运用 PageRank 算法计算 PPI 网络中节点 v 的重要性值 $PR(v)$[25]:

$$PR(v)=(1-d)+d\sum_{i=1}^{n}\frac{PR(v_i)}{deg(v_i)} \tag{1}$$

其中 v_i 是连接 v 的某个节点,$deg(v_i)$ 是节点 v_i 的度,$i=1,2,\cdots,n$;d 为阻尼系数表示从其他节点游走到节点 v 的概率,通常 $d=0.85$[24]. 通过迭代计算,$PR(v)$ 值会趋于稳定,以此表示节点 v 的重要性.

聚类系数(Clustering coefficient)用于衡量节点聚集的程度. PPI 网络中节点 v 的局部聚类系数 $coef(v)$ 量化了其邻居节点相互聚集构成团(完全图)的程度[24]:

$$coef(v)=\frac{2\times E_v}{deg(v)\times(deg(v)-1)} \tag{2}$$

其中 E_v 表示 v 节点周围的邻居节点之间的边数.

至此,可以获得节点 v 的3个特征数据 $deg(v)$、$PR(v)$和 $coef(v)$. 接下来将使用它们构建生成式对抗网络 GAN 中的损失函数.

1.3　网络节点对准

当 PPI 网络中两个节点 u 和 v 相似时,它们的3个特征 $((deg(u),PR(u),coef(u))$ 和 $((deg(v),PR(v),coef(v))$ 组成的向量的欧氏距离是相近的,此外在源网络节点和目标网络节点之间存在节点 u 和 v 之间的相似性得分 s 值,s 值越大,节点 u 和 v 之间的关系越强. 可以将 PPI 网络节点的比对,看成是特征向量在三维空间的映射,通过映射将源网络的特征向量尽可能地映射到目标网络特征向量的空间中,以此完成比对. 这项工作由 GAN 网络中的生成器来完成. 当源网络节点分组输入 GAN 网络时,随着 GAN 网络的不断训练,鉴别器会将映射后的一组源网络节点和一组目标网络节点进行区分各自属于哪个网络;而生成器则会让一组源网络节点尽可能靠近目标网络中的一组节点. 当 GAN 网络鉴别器的正确率 *desc acc* 等于 50% 时,这表明源网络中的节点已经均匀地映射到了目标网络所在的空间中.

1.3.1　生成器网络模型构建

为了对源网络中的特征向量 $eig_s(v_s)$ 进行线性变换,本文构建一个轻量级的生成器多层神经网络模型 G. 该模型由输入层、隐藏层和输出层组成. 输入层规模为 3×256、隐藏层规模为 256×128、输出层规模为 128×3.

1.3.2　鉴别器网络模型构建

为了区分打上标签的源网络节点特征向量和目标网络节点的特征向量(源网络节点向量打上 1 的标签,目标网络向量打上 0 的标签),本文构建一个轻量级的鉴别器多层神经网络模型 D. 该网络输入层使用规模为 3×64 的线性层,后接 Dropout 层随机将其中 40% 的值设置为 0,防止训练过程中过拟合,紧跟 Dropout 层的是一个 ReLU 激活函数. 输入层将接受源网络和目标网络的3维特征向量以及对应的结果集. 接着是结构相似的2个网络结构,它们的线性层节点数分别为 64×128 和 128×256. 最后接一个输出层规模为 256×1 的线性层将向量映射为一个值 *value*,这个 *value* 值为样本的正例得分. 鉴别器的作用是将源网络和目标网络打上正确的标签,因此为一个二分类问题. 使用 Sigmoid 激活函数将 *value* 值转化为概率值 $pre=\delta(value)$ $(0\leqslant pre\leqslant1)$. 使用二分类损失函数值 *loss*(式(3))计算实际标签和真实标签是否具有相同的概率,进行反向传播.

$$loss=C(value[0:m-1])=\left(-\frac{1}{m}\sum_{i=0}^{m-1}y_i\log(\delta(value[i]))+(1-y_i)\log(1-\delta(value[i]))\right) \tag{3}$$

其中 $C(value[0:m-1])$ 为 m 个样本 $value[0:m-1]$ 计算出的损失函数值,用于反向传播进行优化鉴别器 D,y_i 为第 i 个样本的真实标签,$value_i$ 为第 i 个样本的正例得分.

评估鉴别器模型时,若概率值 *pre* 大于等于值 β(默认取值为 0.5),则输出层输出 1;若概率值 *pre* 小于值 β,则输出 0. 这两个 0 和 1 即为实际训练输出的标签,使用正确率 *accuracy* 来评判鉴别器效果,$accuracy=(TP+TN)/(P+N)$,其中 TP 为预测对的正例样本的数量,TN 为预测对的负例样本的数量,P 为预测的正例样本数量,N 为预测的负例样本数量.

1.3.3　网络比对模型训练

首先,对生成器 G 的多层神经网络比对模型进行训练,以完成源和目标蛋白质交互网络节点之间的映射. 训练过程如下:每一轮训练中,从源网络 G_s 和目标网络 G_t 的特征向量集 $eig_s(v_s)$ 和 $eig_t(v_t)$ 分别随机抽取出 m 个节点组成映射训练集. 训练的损失函数值由式(4)的网络比对相似度矩阵得分 S 构成,优化目标为最大化 S. 对生成器 G 进行一轮训练后得到的生成器记 G'.

$$S=\frac{1}{m}\sum_{i=0}^{m-1}SIM(G(v_s[i],v_t[i])) \tag{4}$$

按式(5)计算源网络 $G_s=(V_s,E_s)$ 节点 $v_s\in V_s$ 和目标网络 $G_t=(V_t,E_t)$ 节点 $v_t\in V_t$ 的相似度 $SIM(v_s,v_t)$[18]:

$$SIM(v_s,v_t)=\alpha\times(1-PRD(v_s,v_t))+\beta\times(1-DegDif(v_s,v_t))+\gamma\times(1-CCD(v_s,v_t))+\omega\times Seq(v_s,v_t) \tag{5}$$

$$PRD(v_s,v_t)=\frac{|PR(v_s)-PR(v_t)|}{\max(PR(v_s),PR(v_t))} \tag{6}$$

$$DegDif(v_s,v_t)=\frac{|deg(v_s)-deg(v_t)|}{\max(deg(v_s),deg(v_t))} \tag{7}$$

$$CCD(v_s,v_t)=\frac{|coef(v_s)-coef(v_t)|}{\max(coef(v_s),coef(v_t))} \tag{8}$$

其中 $Seq(v_s,v_t)$ 表示节点 v_s 与 v_t 之间的序列相似性得分,$PRD(v_s,v_t)$ 表示源网络节点 v_s 和目标网络节点 v_t 的 PageRank 值的差值. $PRD(v_s,v_t)$ 越小,表示两个节点 v_s 和 v_t 在它们各自网络中重要性越接近. $DegDif(v_s,v_t)$ 表示源网络节点 v_s 和目标网络节点 v_t 的节点度差值. $DegDif(v_s,v_t)$ 越小,说明节点 v_s 与 v_t 相连的边的数量是接近的. $CCD(v_s,v_t)$ 表示源网络节点 v_s 和目标网络节点 v_t 的聚类系数值之差. $CCD(v_s,v_t)$ 越小,则说明 v_s、v_t 与其分别相连的节点之间聚集成团(*clique*)的程度越相近.

然后,将生成器训练完成得到的 G'和鉴别器 D 组合进行 GAN 网络训练. 训练鉴别器的过程如下:从源网络 G_s 的特征向量 $eig_s(v_s)$ 随机抽取出 m 个特征向量 $eig_s(v_s)[0:m-1]$ 将该 m 个特征向量输入到生成器 G'中得到线性映射 $eig'_s(v_s)[0:m-1]$,对它们打上标签 1,得到源网络的训练集 $sample_s=(eig'_s(v_s)[0:m-1],1)$. 从目标网络 G_t 的特征向量 $eig_t(v_t)$ 随机抽取出 m 个特征向量 $eig_t(v_t)[0:m-1]$,对它们打上标签 0,得到目标网络的训练集 $sample_t=(eig_t(v_t)[0:m-1],0)$,将 *sample_s* 和 *sample_t* 输入到鉴别器 D 中进行训练得到鉴别器 D'. 评估比较鉴别器 D'对源网络训练集 *simple_sd* 的正确率 *sour_acc* 和目标网络训练集 *simple_t* 的正确率 *dest_acc*. 若 *sour_acc* 和 *dest_acc* 越接近 50%,则表明生成式对抗网络 GAN 训练得越好. 本文通过式(9)进行评估,当 $f<0.1$ 时停止训练.

$$f=|sour_acc-0.5|+|dest_acc-0.5| \tag{9}$$

如果 $f<0.1$ 条件不满足,那么需要在 GAN 网络中训练生成器G'. 训练过程为:固定鉴别器 D'参数,从源网络 G_s 的特征向量 $eig_s(v_s)$ 随机抽取出 m 个特征向量 $eig_s(v_s)[0:m-1]$ 并

将这些特征向量输入到生成器 G' 得到与之对应的样本 $sample_s' = (eig'_s(v_s)[0:m-1],1)$. 通过鉴别器 D',根据式(3)训练生成器 G',优化目标为最小化 $loss$,得到生成器 G'',使用 G'' 更新生成器 G 的参数.

依次进行上述过程的训练,直到满足式(9)中 $f<0.1$ 条件,则停止训练,此时得到源蛋白质交互网络 G_s 和目标蛋白质交互网络 G_t 的比对映射关系 G'.

1.4 检索比对结果

当生成器 G 中超参数训练完成时,得到 G',将源网络的节点特征向量 $eig_s(v_s)$ 输入生成器 G',即可得到源和目标 PPI 网络的对准结果. 在 GAN 网络训练过程中,生成器 G 不断将源网络中的特征向量靠近目标网络中的特征向量,当鉴别器无法判断该向量是来自源网络还是目标网络时,则表明源网络的特征向量线性映射到目标网络的特征向量区域.

设节点 v_s 属于 $G'(eig_s(v_s))$,则需要在目标网络空间寻找欧氏距离最短的 V_t 中的节点 v_t,v_s 和 v_t 即可构成一对比对匹配节点. k 维树 KD-tree 是一种空间划分的数据结构,常被用于高维空间中的搜索. 本文运用 KD-tree 算法快速搜索到源网络节点集 V_s 和目标网络节点集 V_t 中所有比对匹配的节点对. 这些节点对即为 PPI 网络全局比对映射匹配的节点对集合结果 M.

1.5 算法描述与分析

设源 PPI 网络 $G_s=(V_s,E_s)$ 和目标 PPI 网络 $G_t=(V_t,E_t)$,节点数 $|V_s|=n_s$,$|V_t|=n_t$. 算法 1 形式描述了本文提出的基于网络嵌入和多特征提取的蛋白质交互网络全局比对算法(简称 NAGNA 算法).

算法 1. NAGNA

输入: $G_s=(V_s,E_s)$,$G_t=(V_t,E_t)$,$|V_s|=n_s$,$|V_t|=n_t$

输出: M

Begin

1. 将网络 G_s 和 G_t 依据 e 值 $<10^{-5}$ 剔除不可靠的 s 值的边,以得到 G_s' 和 G_t';
2. $G_s \leftarrow G_s'$;$G_t \leftarrow G_t'$;
3. for $i=0$ to n_s-1 do
4. 获 G_s 的特征向量集 $eig_s(v_s)$ 按式(1)和(2)分别计算 $PR(v_s[i])$ 和 $coef(v_s[i])$,根据 v_s 节点的度计算 $deg(v_s[i])$;
5. endfor
6. $eig_s(v_s)[i] \leftarrow ((deg(v_s[i]),PR(v_s[i]),coef(v_s[i]))$;
7. for $i=0$ to n_t-1 do
8. 获 G_t 的特征向量集 $eig_t(v_t)$ 按式(1)和(2)分别计算 $PR(v_t[i])$ 和 $coef(v_t[i])$,根据 v_t 节点的度计算 $deg(v_t[i])$;
9. $eig_t(v_t)[i] \leftarrow ((deg(v_t[i]),PR(v_t[i]),coef(v_t[i]))$;
10. endfor
11. for $i=0$ to $epochs-1$ do // 对 GAN 网络训练 $epochs$ 轮
12. 随机从 $eig_s(v_s)$ 和 $eig_t(v_t)$ 中抽取特征 $eig_s(v_s)[0:m-1]$ 和 $eig_t(v_t)[0:m-1]$ 组成训练集;
13. 按式(4)最大化 S 训练生成器 G 得到 G';
14. 计算 $G'(eig_s(v_s)[0:m-1])$;
15. 将 $G'(eig_s(v_s)[0:m-1])$ 打上正例标签 1 得到 $sample_s=(G'(eig_s(v_s)[0:m-1]),1)$;
16. 将 $eig_t(v_t)[0:m-1]$ 打上负例标签 0 得到 $sample_t=(eig_t(v_t)[0:m-1],0)$;
17. 将 $sample_s$ 和 $sample_t$ 送入鉴别器 D 中按式(3)损失函数值 $loss$ 训练鉴别器 D 得到 D',根据正确率 $accuracy$ 计算评估鉴别器 D' 得到的 $sour_acc$ 和 $dest_acc$;
18. 按式(9)计算 f;
19. if $f<0.1$ then
20. $G \leftarrow G'$;
21. break;
22. endif
23. 随机从 $eig_s(v_s)$ 中抽取特征 $eig_s(v_s)[0:m-1]$,然后得到 $sample_s'=(eig_s'[0:m-1],1)$;
24. $value[0:m-1]=D'(G(sample_s'))$;
25. 按式(3)最小化 $loss$ 以得到生成器 G'';
26. $G \leftarrow G''$;
27. $D \leftarrow D'$;
28. endfor
29. for $i=0$ to n_s-1 do
30. $R[i] \leftarrow G(eig_s(v_s)[i])$;//得到映射节点集 R;
31. endfor
32. for $i=0$ to n_s-1 do
33. $eig_v[i] \leftarrow$(执行 KD-tree 算法获得 $\min(R[i],eig_t(v_t))$;
34. $M \leftarrow M \cup (R[i],eig_t(v_t)[i])$;
35. endfor

End

算法 NAGNA 步骤 1 执行剔除源 PPI 网络 G_s 和目标 PPI 网络 G_t 不可靠的 s-$value$ 对应的那些边,其所需时间为 $O(n_s \times n_t)$. 步骤 3 ~ 步骤 10 为获取节点的特征向量集合,计算 $PR(v_s)$ 所需的时间为 $O(n_s^2)$,计算 $deg(v_s)$ 和 $coef(v_s)$ 所需的时间分别为 $O(n_s)$,因此获得源 PPI 网络中特征向量所需的时间为 $O(n_s^2)+2O(n_s)=O(n_s^3)$;同理获得目标 PPI 网络中特征向量所学的时间 $O(n_s^2)$. 步骤 11 ~ 步骤 28 为训练 GAN 网络以获得比对映射 G',每次计算生成器和鉴别器损失函数值所需时间为 $O(n_s)$,训练 $epochs$ 次,共需时间 $O(n_s \times epochs)$. 执行步骤 29 ~ 步骤 31 以获得映射对准节点,其所需时间为 $O(1)$. 步骤 32 ~ 步骤 35 执行 KD-tree 算法搜索源和目标 PPI 网络比对映射匹配节点对,其所需的时间为 $O(n_s \times \log(n_s))$. 于是,算法 NAGNA 的时间复杂度为 $O(n_s \times n_t + n_s^2 + n_t^2 + n_s \times epochs + 1 + n_s \times \log(n_s))$. 由于 $n_s < n_t$,$epoch$ 远小于 n_s,因此算法 NAGNA 的时间复杂度为 $O(n_t^2)$.

算法 NAGNA 使用的特征矩阵 $eig_t(v_t)$ 的规模为 $n_t \times 3$、特征矩阵 $eig_s(v_s)$ 的规模为 $n_s \times 3$、序列比对得分矩阵规模为 $n_s \times n_t$,因此,算法 NAGNA 所需空间规模为 $O(n_t \times 3 + n_s \times 3 + n_s \times n_t) = O(n_s \times n_t)$.

本文算法 NAGNA 通过对 PPI 网络进行噪声处理以剔除蛋白质网络中不可靠的边、提取网络特征计算训练、计算生成器和鉴别器损失函数值,以及使用 GAN 网络搜索到源和目标 PPI 网络的映射关系,并在源 PPI 网络和目标 PPI 网络之间运用 KD-tree 算法寻找源和目标 PPI 网络比对映射匹配节点对. 这样处理将降低 PPI 网络数据缺失对算法结果的影响,且可提高算法的比对结果质量和运行速度.

2 实 验

2.1 实验环境和数据

实验在广西大学 Sugon7000A 超级并行计算机系统上进

行. 使用的计算节点配置为:CPU2 * Intel Xeon Gold 6230 2.1G 共 40 核,内存 DDR4 192GB,外部存储 8 * 900GB,操作系统 CentOS7.4. 使用 Python3.7 语言编程实现算法,生成式对抗网络 GAN 使用 TensorFlow 开源平台训练.

Isobase (IsoRank PPI Network Alignment Based Ortholog Database)是一个功能相关的同源数据库[26]. 本文实验使用 Isobase 数据库提供的数据文件 ppi_networks.1.0.2.tar.gz,它包含 5 种生物 PPI 网络结构,通过预处理去掉重复边和自循环节点后,统计其信息如表 1 所示.

表 1　实验数据集的生物网络信息

Table 1　Biological network information of data set

物　种	缩写	节点数	边数
C. elegans(秀丽隐杆线虫)	CE	19782	270800
D. melanogaster(黑腹果蝇)	DM	14039	107848
H. Sapiens(智人)	HS	22232	502635
M. musculus(小家鼠)	MM	24267	658533
S. cerevisiae(酿酒酵母)	SC	6613	18629

Isobase 数据库中的 BLAST_Bit_Scores.tar.gz 提供了表 1 中 5 种物种两两 PPI 中的蛋白质序列比对得分 s 值.

2.2　性能评价指标

本文使用拓扑和生物学有关指标度量评价蛋白质交互网络比对算法的性能.

在拓扑度量方面,若源 PPI 网络 $G_s=(V_s,E_s)$ 中的两个节点 a 和 b 映射匹配到目标 PPI 网络 $G_t=(V_t,E_t)$ 中的两个节点 C 和 D,且节点 a 和节点 b 之间存在边 (a,b)、节点 C 和节点 D 之间也存在边 (C,D),则称这一对边为保守边(conserved edges). 边保守说明参与比对的蛋白质保守,即该对节点相似,算法比对结果的拓扑质量高. 与保守边相关的度量常用的有 3 个:边正确性(Edge correctness,EC)[27]、诱导保守结构(Induced conserved structure,ICS)[28]以及对称子结构得分(Symmetric substructure score,S^3)[29]. 为方便表述和讨论,设 $|E_c|$ 表示比对完成后所形成的保守边的数量,$|E_s|$ 表示源网络中的边数,$|E_t'|$ 参与比对的节点形成的诱导子图 E_t' 的边数.

为更好地说明 EC、ICS 和 S^3 这 3 个拓扑比对度量的内涵,设 G_s 和 G_t 的映射比对结果如图 2 所示,虚线表示两个节点映射,实线表示节点之间的相互作用.

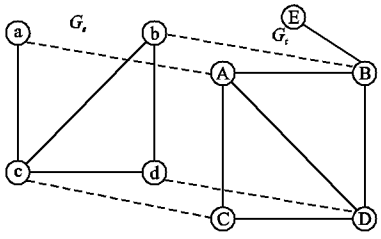


图 2　G_s 和 G_t 映射比对示例

Fig. 2　Example for mapping alignment between networks G_s and G_t

从图 2 可知,保守边的数量为 3,分别为(a,c)和(A,C),(c,d)和(C,D),(b,d)和(B,D),即 $|E_c|=3$,$|E_s|=4$,目标网络中的诱导子图边数 $|E_t'|=5$.

边正确性 EC 指标表示保守边与源 PPI 网络边数的比值,该指标希望保守边尽可能覆盖源 PPI 网络.

$$EC(f)=\frac{|E_c|}{|E_s|} \tag{10}$$

其中 f 表示源和目标 PPI 网络之间的映射关系. 对于图 2 中边正确性 $EC=3/4=0.75$.

诱导保守结构指标表示保守边与目标 PPI 网络中参与比对的节点形成的诱导子图的边的比值.

$$ICS(f)=\frac{|E_c|}{|E_t'|} \tag{11}$$

该 ICS 指标希望保守边尽可能地覆盖目标网络中的对应的诱导子图 $|E_t'|$. 对于图 2 中,$ICS=3/5=0.6$.

对称子结构得分 S^3 指标综合了 EC 和 ICS 两个指标,同时兼顾到源和目标 PPI 网络[29].

$$S^3(f)=\frac{|E_c|}{|E_s|+|E_t'|-|E_c|} \tag{12}$$

对于图 2,对称子结构得分 $S^3=3/6=0.5$.

在生物学度量方面,希望比对对准的源和目标网络蛋白质节点在生物功能方面也应一致. 使用计算两个蛋白质功能一致性评价指标 FC 指标度量[30]. 在生物学中,基因本体术语(gene ontology term,GO term)被用来注释蛋白质在生物功能方面的特性. GO term 是一个树型结构,且越靠近根部注释越抽象,越靠近叶节点越具体. 本文与文献[29]一样,只考虑第 5 层的注释,且将第 5 层节点的子树中的注释归结到第 5 层. 本文使用 $GO(i)$ 表示节点 i 被注释的 GO term 的集合. 基因同源一致性(Gene Ontology Consistency,GOC)是基于比对节点的 GO term 一致性来衡量比对结果生物特性. 设 f 为比对结果映射,则 $FC(f)$ 计算如下[29]:

$$FC(f)=\frac{GOC(f)}{|V_s|} \tag{13}$$

其中 $FC(f)$ 是比对结果 $GOC(f)$ 的均值,$GOC(f)$ 计算如下[29]:

$$GOC(f)=\sum_{v\in V_s}\frac{|GO(v)\cap GO(v')|}{|GO(v)\cup GO(v')|} \tag{14}$$

式(14)中的 v' 表示源 PPI 网络节点 v 对应的目标 PPI 网络中的节点. 当节点 v 和 v' 对应的第 5 层 GO term 注释完全一致时,这对节点的蛋白质功能完全一致. $GOC(f)$ 表示在映射结果 f 中,源网络节点 v 和其对应目标网络节点 v' 的第 5 层 GO term 注释集合的交集数量和并集数量的商之和.

2.3　实验结果

实验将本文算法 NAGNA 与已有的同类代表性算法 MAGNA++[14]、L-GRAAL[31]、ModuleAlign[32]和 AligNet[33]进行测试比较. 其中 MAGNA++是 MAGNA 算法的扩展,其特点是优化边之间的匹配;L-GRAAL 是 GRAAL 家族中最新的网络比对算法,使用种子-扩展的贪婪方法作为比对策略;ModuleAlign 和 AligNet 使用了模块化的思想进行网络比对. 实验中,参与比较的已有算法的实验参数设置采用其原文中的参数值,MAGNA++算法参数 $p=15000$、$n=2000$、$m=S^3$;ModuleAlign 算法参数 $A=0.4$. 算法 L-GRAAL 和 AligNet 没有参数. 本文算法 NAGNA 使用的相似性矩阵得分 SIM 中的参数 $\alpha=0.1$、$\beta=0.2$、$\gamma=0.2$ 和 $\omega=0.5$,GAN 网络训练轮数

为 400.

为了获得最佳的模型训练次数,实验首先依次训练生成器 G 和鉴别器 D,根据每一轮鉴别器 D 对源 PPI 网络评估的正确率 *sour_acc* 和对目标 PPI 网络评估的正确率 *dest_acc* 绘制出图 3 所示的折线图.

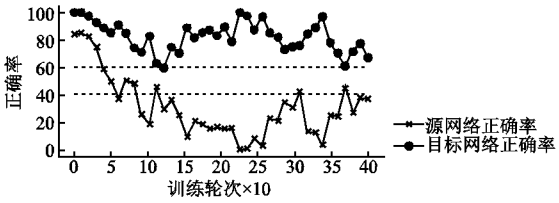


图 3 算法 NAGNA 中的鉴别器 D 对源网络评估正确率 *sour_acc* 和对目标网络评估的正确率 *dest_acc* 变化情况

Fig. 3 Variation of correct assessment rates *sour_acc* for source network and *dest_acc* for target network by discriminator D in algorithm NAGNA

GAN 网络中,理想的训练目标为:鉴别器对真实数据和生成器生成的数据的检测正确率各为 50% 时,生成式对抗网络训练结束,表明源和目标 PPI 网络映射完成. 从图 3 可见,当生成器和鉴别器的正确率靠近 50% 时,生成式对抗网络训练结束,表明源和目标 PPI 网络映射比对完成. 从图 3 中也可以看出,在第 370 轮的训练结果中,其鉴别器模型评估的正确率相较于其他轮次更靠近 50%. 因此,本文后续实验使用该轮次训练的模型(映射函数);执行 KD-tree 算法搜索源 PPI 网络映射比对到目标 PPI 网络的结果,进而得到最终的蛋白质交互网络全局比对结果.

本文研究的是成对蛋白质交互网络全局比对问题,该类比对问题的算法的验证需要使用到源蛋白质交互网络和目标蛋白质交互网络所形成的数据对,因此本文对 5 种蛋白质交互网络数据两两组合进行测试,以得到本文提出的算法和其他同类算法运行比对结果的拓扑质量得分 *EC*、*ICS* 和 S^3 以及生物质量得分 *FC*,进而评价得出算法的比对质量. 5 种算法实验得到的比对结果的 *EC* 值、*ICS* 值、S^3 和 *FC* 值分别如表 2 ~ 表 5 所示.

表 2 算法在不同数据集上运行得到的 *EC* 值

Table 2 *EC* values of running algorithms on different datasets

数据集 \ 算法	MAGNA ++	L-GRAAL	ModuleAlign	AligNet	NAGNA
SC-CE	0.732	0.561	**0.766**	0.331	**0.766**
SC-DM	0.085	0.081	**0.090**	0.061	0.089
SC-HS	0.140	0.119	0.677	0.071	**0.729**
SC-MM	0.981	0.376	0.753	0.724	**0.992**
DM-CE	0.510	**0.611**	0.590	0.342	0.592
DM-HS	0.240	0.320	0.378	0.331	**0.392**
DM-MM	0.881	0.413	0.574	0.692	**0.901**
CE-HS	0.414	0.566	**0.661**	0.372	0.545
CE-MM	**0.790**	0.501	0.491	0.663	0.411
HS-MM	**0.560**	0.512	0.392	0.472	0.433

表 2 的结果表明:对于 *EC* 值,本文算法 NAGNA 在 5 种物种对 SC-CE、SC-HS、SC-MM、DM-HS 和 DM-MM 数据集上均高于其他 4 种算法;在 SC-DM 和 DM-CE 数据集上略低于算法 ModuleAlign 和 L-GRAAL;对于 CE-MM、CE-HS 和 HS-MM 数据集,本文算法 NAGNA 的 *EC* 值低于算法 AligNet、ModuleAlign 和 AligNet. 从这些实验结果看,本文算法获得的 *EC* 值多数情形下较其他 4 种算法有优势.

表 3 算法在不同数据集上运行得到的 *ICS* 值

Table 3 *ICS* values of running algorithms on different datasets

数据集 \ 算法	MAGNA ++	L-GRAAL	ModuleAlign	AligNet	NAGNA
SC-CE	0.065	0.090	0.067	0.040	**0.095**
SC-DM	0.321	0.304	0.372	0.190	**0.391**
SC-HS	0.240	0.227	0.251	0.138	**0.261**
SC-MM	0.061	0.252	0.075	0.094	**0.263**
DM-CE	0.195	**0.343**	0.201	0.221	0.291
DM-HS	0.212	0.205	0.378	0.197	**0.412**
DM-MM	0.231	0.357	0.163	0.291	**0.401**
CE-HS	0.241	**0.342**	0.661	0.252	0.251
CE-MM	**0.371**	0.301	0.200	0.410	0.322
HS-MM	**0.660**	0.502	0.392	0.564	0.423

从表 3 可以看到:本文算法 NAGNA 在其中 6 种数据集上运行获得的 *ICS* 值高于其他 4 种算法;在 DM-CE 和 CE-HS 数据集上获得的 *ICS* 值低于算法 L-GRAAL,在数据集 CE-MM 和 HS-MM 上获得的 *ICS* 值低于算法 MAGNA + +. 总体而言,对于 *ICS* 值,本文算法 NAGNA 高于其他 4 种算法.

关于 S^3 指标得分,从表 4 可以看出:本文算法 NAGNA 在其中 6 种数据集上获得较高的 S^3 得分,算法 MAGNA + +、L-GRAAL 和 AligNet 分别在其中 1 种数据集获得了较高的 S^3 值,算法 ModuleAlign 则在其中 2 种数据集上获得了较高的 S^3 值. 这些结果表明,本文算法 NAGNA 在 S^3 指标评价方面多数情况下优于其他 4 种算法.

表 4 算法在不同数据集上运行得到的 S^3 值

Table 4 S^3 values of running algorithms on different datasets

数据集 \ 算法	MAGNA ++	L-GRAAL	ModuleAlign	AligNet	NAGNA
SC-CE	0.063	0.084	0.066	0.037	**0.092**
SC-DM	0.072	0.068	**0.078**	0.048	**0.078**
SC-HS	0.096	0.084	0.224	0.049	**0.238**
SC-MM	0.061	0.178	0.073	0.091	**0.262**
DM-CE	0.164	**0.282**	0.176	0.155	0.242
DM-HS	0.127	0.143	0.233	0.141	**0.251**
DM-MM	0.224	0.237	0.145	0.258	**0.384**
CE-HS	0.180	0.271	**0.494**	0.177	0.208
CE-MM	0.334	0.232	0.166	**0.339**	0.221
HS-MM	**0.461**	0.451	0.391	0.453	0.272

对于指标 *FC* 值,从表 5 可见:本文算法 NAGNA 仍然在其中 5 种数据集上获得了较高的 *FC* 值,算法 MAGNA + + 和 ModuleAlign 分别在其中 1 种数据集上获得较高的 *FC* 值,算法 AligNet 则在其中 4 种数据集上获得了较高的 *FC* 值. 这表明,5 种算法中,本文算法 NAGNA 比对结果的生物学意义性能表现更好,其次是算法 AligNet. 算法 AligNet 之所以比其他已有的 3 种算法获得 *FC* 值第二高,是因为算法 AligNet 通过

模块化方法,缩小了拓扑高效和生物学意义的匹配之间的差距,使得其生物学意义较高.

表 5　算法在不同数据集上运行得到的 *FC* 值

Table 5　*FC* values of running algorithms on different datasets

数据集＼算法	MAGNA ++	L-GRAAL	ModuleAlign	AligNet	NAGNA
SC-CE	0.011	0.011	0.023	**0.061**	**0.061**
SC-DM	0.021	0.010	0.029	0.053	**0.054**
SC-HS	0.024	0.012	0.058	0.061	**0.063**
SC-MM	0.032	0.011	0.054	0.081	**0.090**
DM-CE	**0.098**	0.005	0.096	0.039	0.015
DM-HS	0.032	0.007	0.378	**0.058**	0.052
DM-MM	0.020	0.006	0.025	0.043	**0.049**
CE-HS	0.025	0.012	**0.661**	0.048	0.017
CE-MM	0.021	0.012	0.019	**0.063**	0.052
HS-MM	0.031	0.006	**0.368**	0.047	0.016

综合表 2 ~ 表 5 的结果可知,本文提出的算法 NAGNA 相较于其他 4 种同类算法具有整体上较高的比对结果质量. 这是因为:一方面,由于生物实验技术发展不完善以及蛋白质活动的动态与复杂性,构建的真实网络可能会存在数据不全或者噪声导致的出现不存在的顶点和相互作用边,本文算法 NAGNA 根据 Blast 序列比对得分的 *e-value* 值尽可能剔除了这些顶点和边,使实验数据更加可靠;实验过程中提取每个节点的 3 个特征数据 $deg(v)$、$PR(v)$ 和 $coef(v)$,通过不同节点之间的序列相似性得分从不同角度更准确地描述节点. 另一方面,与算法 ModuleAlign 和 AligNet 从局部入手进行比对不同,本文算法 NAGNA 每次从参与比对的 PPI 网络的全局节点中随机选取一批节点进行映射关系的训练,这样可以更好地反应节点在整个 PPI 网络比对中的影响,而不会陷入局部最优;相对于算法 MAGNA + + 只采用一种拓扑指标作为目标优化不同,本文算法 NAGNA 从生物指标和拓扑指标两个方面进行目标优化,可以更好地平衡这两方面对比对结果质量的影响.

为进一步分析说明为何本文算法 NAGNA 在 SC-MM、SC-HS、SC-CE、DM-MM 和 DM-HS 这 5 种数据集上比对表现更好而在其他数据集上比对性能相对较低的原因,本文统计了算法 NAGNA 和其他 4 种算法各物种之间的节点数量差以及相关的拓扑质量值和生物质量值. 使用式(15)的拓扑质量均差 *TA* 和式(16)的生物质量均差 *FA*,评价比对结果的拓扑质量和生物质量,使用 *TAO* 表示 5 种算法在一对数据集上将源和目标 PPI 网络进行比对得到的拓扑质量得分均值,使用 *FAO* 表示 5 种算法在一对数据集上将源和目标 PPI 网络进行比对得到的生物质量得分均值,使用 *N_S3* 表示 5 种算法将一对数据集上对源和目标 PPI 网络进行比对得到的拓扑质量得分,使用 *N_FC* 表示 5 种算法将一对数据集上对源和目标 PPI 网络进行比对得到的生物质量得分均值. 当 $TA>0$ 和 $FA>0$ 时,表明某个算法在该数据集上的比对得分分别高于所有其他算法的拓扑质量得分的均值和生物质量得分的均值,此时该算法在这 5 种算法中比对质量表现最好.

$$TA=\frac{N_S3\text{-}TAO}{TAO} \tag{15}$$

$$FA=\frac{N_FC-FAO}{FAO} \tag{16}$$

表 6 和表 7 给出了 5 种算法比对结果的拓扑质量均差 *TA* 与生物质量均差 *FA*,并给出算法在所有数据集上 $TA>0$ 和 $FA>0$ 的统计数量.

从表 6 的结果可以看出,在拓扑质量均差 *TA* 方面,本文算法 NAGNA 在 7 个数据集上 $TA>0$,它是所有 5 种算法中最多的. 表 7 的结果表明,在生物质量均差 *FA* 方面,算法 NAGNA 与算法 ModuleAlign 和 AligNet 具有相同的 $FA>0$ 的数量 6;但是算法 NAGNA 获得的 $TA>0$ 的数量比算法 ModuleAlign 和 AligNet 更多. 这表明,本文算法 NAGNA 在综合 *TA* 和 *FA* 的整体表现上要优于其余 4 种算法.

表 6　算法在不同数据集上比对结果的拓扑质量均差 *TA*

Table 6　*TA* values for aligned results of running algorithms on different datasets

数据集	节点数量差	MAGNA ++	L-GRAAL	ModuleAlign	AligNet	NAGNA
SC-MM	17654	−0.541	0.338	−0.451	−0.316	0.970
SC-HS	15619	−0.305	−0.392	0.621	−0.645	0.722
SC-CE	13169	−0.079	0.228	−0.035	−0.459	0.345
DM-MM	10228	−0.103	−0.050	−0.419	0.034	0.538
DM-HS	8193	−0.291	−0.201	0.302	−0.212	0.402
SC-DM	7426	0.047	−0.012	0.134	−0.302	0.134
DM-CE	5743	−0.195	0.384	−0.136	−0.239	0.187
CE-MM	4485	0.293	−0.102	−0.358	0.312	−0.145
CE-HS	2450	−0.323	0.019	0.857	−0.335	−0.218
HS-MM	2035	0.137	0.112	−0.036	0.117	−0.329
TA 值 >0 的数量		3	5	4	3	7

为了直观展示在 10 种数据集上源 *PPI* 网络节点数量和目标 *PPI* 网络节点数量之差对 5 种算法性能的影响,将表 6 和表 7 的结果数据分别绘制成图 4 和图 5.

表 7　算法在不同数据集上比对结果的生物质量均差 *FA*

Table 7　*FA* values for aligned results of running algorithms on different datasets

数据集	节点数量差	MAGNA ++	L-GRAAL	ModuleAlign	AligNet	NAGNA
SC-MM	17654	−0.403	−0.795	0.007	0.511	0.679
SC-HS	15619	−0.450	−0.725	0.330	0.399	0.445
SC-CE	13169	−0.671	−0.671	−0.311	0.826	0.826
DM-MM	10228	−0.301	−0.790	−0.126	0.503	0.713
DM-HS	8193	−0.696	−0.934	2.586	−0.450	−0.507
SC-DM	7426	−0.371	−0.701	−0.132	0.587	0.617
DM-CE	5743	0.937	−0.901	0.897	−0.229	−0.704
CE-MM	4485	−0.371	−0.641	−0.431	0.886	0.557
CE-HS	2450	−0.836	−0.921	3.332	−0.685	−0.889
HS-MM	2035	−0.669	−0.936	2.932	−0.498	−0.829
FA 值 >0 的数量		1	0	6	6	6

从图 4 和图 5 可以看到,当源 PPI 网络 G_s 和目标 PPI 网络 G_t 的节点数量之差较大(即源 PPI 网络规模较小、目标 PPI 网络规模较大)时,算法 NAGNA 运行结果的拓扑质量均差 *TA* 值较大;当源网络 G_s 和目标网络 G_t 的节点数量之差缩小(规模之差≤5743),即源蛋白质交互网络规模与比对的目标

蛋白质交互网络规模逐步接近时,算法 NAGNA 运行结果的拓扑质量均差 *TA* 值下降. 算法 L-GRAAL、MAGNA + + 和 AligNet 的 TA 值曲线在 0 值附近较为平稳,总体趋势随着参与比对的源和目标网络即节点数量差距的缩小,*TA* 质量值增加不明显. 另一方面,对于比对结果的生物质量,算法 MAGNA + +、NAGNA 和 AligNet 的 *FA* 曲线在 *FA* = 0 值附近较为平稳,总体趋势为随着参与比对的源和目标网络节点数量差值的缩小,*FA* 质量值减小的不明显;算法 L-GRAAL 的 *FA* 值在 0 以下,较为稳定. 而算法 ModuleAlign 不管是在 *TA* 质量值还是 *FA* 质量值,都比其余 4 种算法波动大. 这些表明,源网络和目标网络节点数量差变化对算法 L-GRAAL、MAGNA + +、和 AligNet 的拓扑质量和生物质量影响较小;算法 ModuleAlign 是 5 种算法中对节点数量之差最为敏感的算法,波动最大. 本文算法 NAGNA 拓扑质量对节点数量变化较为敏感,而生物质量对节点数量值变化不太敏感,这表明本文算法 NAGNA 更适用于比对那些源和目标网络规模相差较大的 PPI 网络数据(实际应用环境中,大多数数据集属于这种类型),在该类数据上能取得比其他算法更好的效果. 通过对算法 NAGNA 自身的分析发现,这是因为当将节点数量较少的源 PPI 网络映射比对到节点数量较多的目标 PPI 网络的时候,生成式对抗网络能够将源 PPI 网络大多数的节点映射比对匹配到目标 PPI 网络空间中;而当源和目标 PPI 网络节点数量差距较小时,源 PPI 网络中的节点很难映射到目标 PPI 网络空间中,难以找到目标 PPI 网络中合适的映射匹配节点.

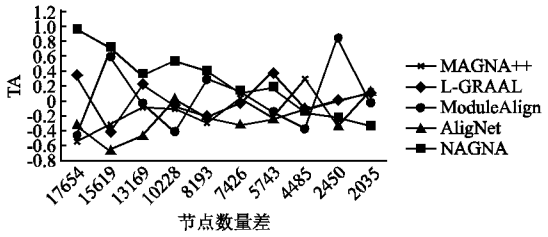


图 4 5 种算法在 10 种数据集上源和目标网络节点数量差的拓扑质量均差 *TA*

Fig. 4 *TA* values for difference of numbers of nodes for source and target networks of running five algorithms on ten datasets

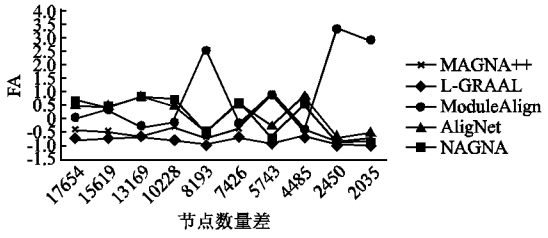


图 5 5 种算法在 10 种数据集上源和目标网络节点数量差的生物质量均差 *FA*

Fig. 5 *FA* values for difference of numbers of nodes for source and target networks of running five algorithms on ten datasets

综上所述,本文算法 NAGNA 更适合比对那些源 PPI 网络和目标 PPI 网络中节点数量相差较大的蛋白质交互网络对,比对结果整体质量和拓扑质量高于其他算法. 值得注意的是在实际的应用环境中,源蛋白质交互网络规模与要比对的目标蛋白质交互网络规模一般相差较大,也即源蛋白质交互网络节点数量较少、目标蛋白质交互网络节点数量较多. 因此,与其他 4 种算法相比,本文算法 NAGNA 在实际环境中具有更好的应用前景.

3 结束语

本文提出的网络嵌入和多特征提取的蛋白质交互网络全局比对方法的特色和新意之处是:使用节点序列比对得分的 *e*-值来过滤掉不可靠的序列相似性值,从而剔除了不信任的节点和与之相邻的边;提取参与比对的源和目标 PPI 网络蛋白质节点的拓扑特征和序列相似性特征,获得源网络节点和目标网络的嵌入;通过训练生成式对抗网络来得到源和目标 PPI 网络节点的比对映射关系,且通过执行 KD-tree 算法得到比对映射匹配结果的节点对结果集合;算法运行高效,整体上比对结果综合拓扑和生物质量更高,在实际环境中具有更好的应用前景. 下一步的工作研究将算法扩展到当源和目标 PPI 网络规模差距较小时也能获得较高质量的比对结果,以及减小对生物指标质量的波动性影响.

References:

[1] Oltvai Z N, Barabási A L. Life's complexity pyramid[J]. Science, 2002, 298(5594): 763-764.

[2] Todor A, Dobra A, Kahveci T. Probabilistic biological network alignment[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2012, 10(1): 109-121.

[3] Uetz P, Dong Y A, Zeretzke C, et al. Herpesviral protein networks and their interaction with the human proteome[J]. Science, 2006, 311(5758): 239-242.

[4] Cardona G, Rosselló F, Valiente G. Comparison of tree-child phylogenetic networks[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2008, 6(4): 552-569.

[5] Bogdanov P, Singh A K. Molecular function prediction using neighborhood features[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2009, 7(2): 208-217.

[6] Flannick J, Novak A, Srinivasan B S, et al. Graemlin: general and robust alignment of multiple large interaction networks[J]. Genome Research, 2006, 16(9): 1169-1181.

[7] Singh R, Xu J, Berger B. Pairwise global alignment of protein interaction networks by matching neighborhood topology[C]//Proceedings of Annual International Conference on Research in Computational Molecular Biology, Heidelberg: Springer, 2007: 16-31.

[8] Van Eck P, Blanken H, Wieringa R. Project GRAAL: towards operational architecture alignment[J]. International Journal of Cooperative Information Systems, 2004, 13(3): 235-255.

[9] Neyshabur B, Khadem A, Hashemifar S, et al. NETAL: a new graph-based method for global alignment of protein-protein interaction networks[J]. Bioinformatics, 2013, 29(13): 1654-1662.

[10] Grewal S I S, Klar A J S. A recombinationally repressed region between mat2 and mat3 loci shares homology to centromeric repeats and regulates directionality of mating-type switching in fission yeast[J]. Genetics, 1997, 146(4): 1221-1238.

[11] Hashemifar S, Xu J. Hubalign: an accurate and efficient method for global alignment of protein-protein interaction networks[J]. Bioin-

formatics,2014,30(17):i438-i444.
[12] Chindelevitch L, Ma C Y, Liao C S, et al. Optimizing a global alignment of protein interaction networks[J]. Bioinformatics, 2013, 29(21):2765-2773.
[13] Saraph V, Milenkovi ć T. MAGNA: maximizing accuracy in global network alignment[J]. Bioinformatics, 2014, 30(20):2931-2940.
[14] Vijayan V, Saraph V, Milenkovi ć T. MAGNA + +: maximizing accuracy in global network alignment via both node and edge conservation[J]. Bioinformatics, 2015, 31(14):2409-2411.
[15] Clark C, Kalita J. A multiobjective memetic algorithm for PPI network alignment[J]. Bioinformatics, 2015, 31(12):1988-1998.
[16] LIU X, CHEN J, WANG Z X. A divide-and-conquer and integration algorithm for pairwise alignment of PPI networks[J]. CAAI Transactions on Intelligent Systems, 2022, 17(5):960-968.
[17] LIU X, CHEN J. Biological network alignment algorithm combining multiple topological information[J]. Journal of Chinese Computer Systems, 2021, 42(10):2173-2177.
[18] Corominas G R, Blesa M J, Blum C. AntNetAlign: ant colony optimization for network alignment[J]. Applied Soft Computing, 2023, 132: 109832, doi: 10.1016/j.asoc.2022.109832.
[19] Menor Flores M, Vega Rodríguez M A. Boosting-based ensemble of global network aligners for PPI network alignment[J]. Expert Systems with Applications, 2023, 230: 120671, doi: 10.1016/j.eswa.2023.120671.
[20] Goodfellow I, Pouget Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11):139-144.
[21] Brown R A. Building a balanced kd tree in o (kn log n) time[J]. arXiv preprint arXiv:1410.5420, 2014.
[22] Ye J, McGinnis S, Madden T L. BLAST: improvements for better sequence analysis[J]. Nucleic Acids Research, 2006, 34(2): W6-W9, doi: 10.1093/nar/gkl164.
[23] Ma L, Shao Z, Li L, et al. Heuristics and metaheuristics for biological network alignment: a review[J]. Neuro Computing, 2022, 491: 426-441, doi: 10.1016/j.neucom.2021.08.156.
[24] Li Y, Shang Y, Yang Y. Clustering coefficients of large networks[J]. Information Sciences, 2017, 382: 350-358, doi: 10.1016/j.ins.2016.12.027.
[25] Duhan N, Sharma A K, Bhatia K K. Page ranking algorithms: a survey[C]//Proceedings of IEEE International Advance Computing Conference, 2009: 1530-1537.
[26] Park D, Singh R, Baym M, et al. IsoBase: a database of functionally related proteins across PPI networks[J]. Nucleic Acids Research, 2010, 39(1): D295-D300.
[27] Kuchaiev O, Milenkovi ć T, Memiševi ć V, et al. Topological network alignment uncovers biological function and phylogeny[J]. Journal of the Royal Society Interface, 2010, 50(7):1341-1354.
[28] Patro R, Kingsford C. Global network alignment using multiscale spectral signatures[J]. Bioinformatics, 2012, 28(23):3105-3114.
[29] Saraph V, Milenkovi ć T. MAGNA: maximizing accuracy in global network alignment[J]. Bioinformatics, 2014, 30(20):2931-2940.
[30] Singh, Rohit, Jinbo Xu, et al. Global alignment of multiple protein interaction networks with application to functional orthology detection[J]. Proceedings of the National Academy of Sciences, 2008, 105(35):12763-12768.
[31] Malod Dognin N, Pržulj N. L-GRAAL: lagrangian graphlet-based network aligner[J]. Bioinformatics, 2015, 31(13):2182-2189.
[32] Hashemifar S, Ma J, Naveed H, et al. ModuleAlign: module-based global alignment of protein-protein interaction networks[J]. Bioinformatics, 2016, 32(17):i658-i664.
[33] Alcalá A, Alberich R, Llabrés M, et al. AligNet: alignment of protein-protein interaction networks[J]. BMC Bioinformatics, 2020, 21(6):1-22.

附中文参考文献:

[16] 刘　晓,陈　璟,王子祥. 用于成对 PPI 网络比对的分治与整合算法[J]. 智能系统学报,2022,17(5):960-968.
[17] 刘　晓,陈　璟. 融合多种拓扑信息的生物网络比对算法[J]. 小型微型计算机系统,2021,42(10):2173-2177.